制作清晰简洁的学术汇报PPT只需学会这几招

笔记本:	b论文写作		
创建时间:	2020/5/24 22:27	**更新时间:**	2020/5/29 11:59
作者:	beyourselfwb@163.com		

1、大纲清晰
2、多种字体颜色
3、使用母语（中文）
4、模型方面，不同模块使用红框圈起来表示
5、实验结果图表方面，对于信息量大的图表，在以此列出结论的同时，使用不同底色的背景标注对应的数据结果
6、能用例子尽量用例子，相比于公式和代码，例子更易于理解
7、语言上吐字清晰，语言流畅，起承转合

南开大学的PPT模板非常好！

参考 南开大学 陈少维 PPT

这是非常典型的一个大纲，四个部分：

1、研究背景与动机（包括任务描述、现存问题/挑战）

2、提出的方法/模型

3、实验分析

4、总结

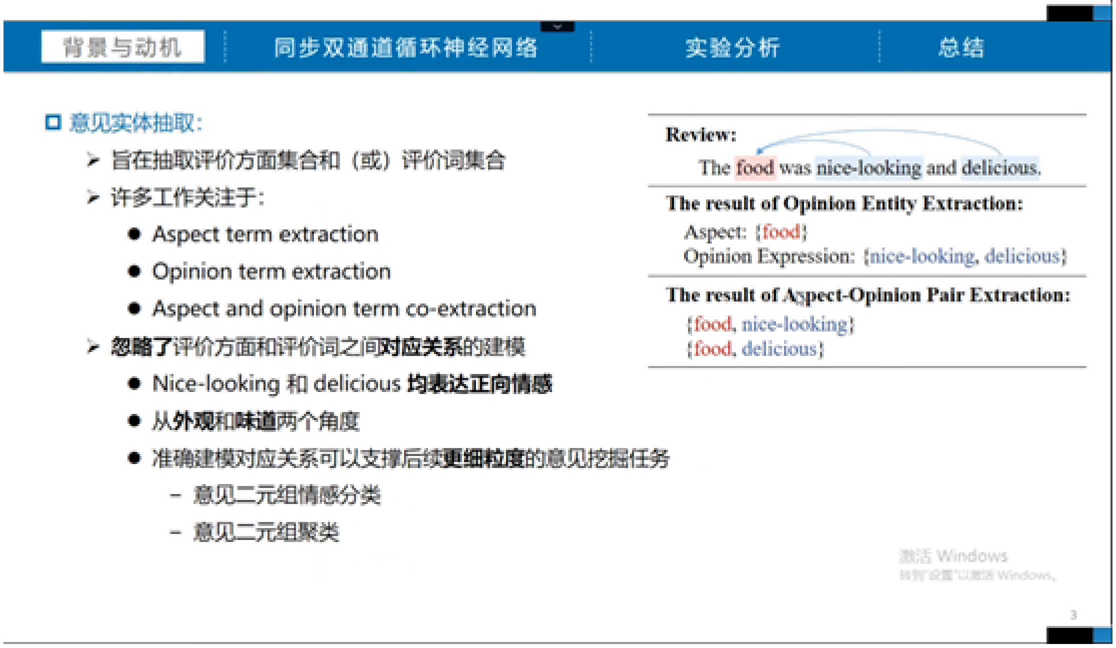

- 意见二元组抽取（Aspect-Opinion Pair Extraction，AOPE）
  - 相关研究工作较少
  - 三个主要挑战：
    - **如何准确识别对应关系**
      - 关系结构复杂
      - 可能存在一对多、多对一、嵌套、交叠等
    - **如何恰当融合意见实体抽取和关系检测两个子任务**
      - 相互依赖
    - **如何同步抽取实体和关系，并使得两者相互指导**
      - “hot dog” 和 “tasty”
      - 结合实体整体语义有助于识别关系
      - 检测到两个词存在对应关系，则一个应为评价方面，另一个为评价词

Review :

The food and service in this bar are perfect and unforgettable.

The result of Aspect Extraction:
{ food, service }

The result of Opinion Expression Extraction:
{ perfect, unforgettable }

Results of Aspect-Opinion Pair Extraction:
(food , perfect)
(food , unforgettable)
(service , perfect)
(service , unforgettable)

目录

内容目录

- 基于同步双通道循环神经网络的意见二元组抽取模型
  (Synchronous Double-channel Recurrent Network，SDRN)
  - **编码层**：BERT
    - 学习更丰富的上下文语义
  - **同步双通道循环网络**
    - **意见实体抽取单元**：CRF
      - 准确识别实体边界
    - **关系检测单元**：Self-Attention
      - 识别复杂的对应关系
    - **信息同步单元**
      - 使两通道相互指导、相互促进

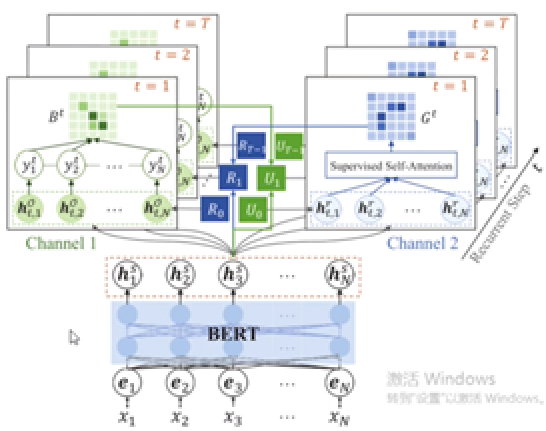

编码层 (Encoding Layer)

- BERT 作为编码层，**学习丰富的上下文语义**
- 将 BERT 中最后一层 Transformer 的输出作为上下文表示序列$H^s = \{\boldsymbol{h}_1^s, \boldsymbol{h}_2^s, \ldots, \boldsymbol{h}_N^s\}$

- 词初始向量表示：

$$\boldsymbol{e}_i = \boldsymbol{e}_i^w + \boldsymbol{e}_i^s + \boldsymbol{e}_i^p$$

其中，$\boldsymbol{e}_i^w$为词嵌入表示，$\boldsymbol{e}_i^s$为段落嵌入表示，$\boldsymbol{e}_i^p$为位置嵌入表示

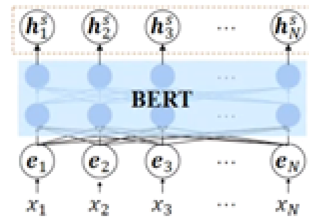

双通道结构（Double-channel）

- 意见实体抽取单元 (Opinion Entity Extraction Unit)
  - **CRF：准确识别意见实体边界**
- 关系检测单元 (Relation Detection Unit)
  - **词级别自注意力机制：识别复杂的对应关系**

条件随机场（CRF）：

$$P^t = H_t^O W_p + b_p$$

$$S(X, Y^t) = \sum_{i=1}^{N} Q_{y_{i-1}^t y_i^t} + \sum_{i=1}^{N} P_{i,y_i^t}^t$$

$$p(Y^t|X) = \frac{\exp\left(S(X, Y^t)\right)}{\sum_{\tilde{Y}^t \in Y_X^t} \exp\left(S(X, \tilde{Y}^t)\right)}$$

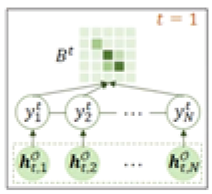

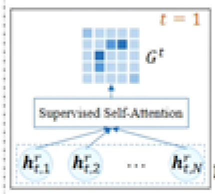

词级别自注意力机制：

$$g_{i,j}^t = \frac{\exp\left(\gamma\left(\boldsymbol{h}_{t,i}^r, \boldsymbol{h}_{t,j}^r\right)\right)}{\sum_{k=1}^{N} \exp\left(\gamma\left(\boldsymbol{h}_{t,i}^r, \boldsymbol{h}_{t,k}^r\right)\right)}$$

$$\gamma\left(\boldsymbol{h}_{t,i}^r, \boldsymbol{h}_{t,j}^r\right) = \tanh\left(\boldsymbol{h}_{t,i}^r W_r^1 + \boldsymbol{h}_{t,j}^r W_r^2\right) W_r^3$$

$$p\left(z_{i,j}|x_i, x_j\right) = \begin{cases} g_{i,j}^t, & if\ \ z_{i,j} = 1 \\ 1 - g_{i,j}^t, & if\ \ z_{i,j} = 0 \end{cases}$$

对最后一个循环步构建损失：

$$\mathcal{L}_E = \log \sum_{\tilde{Y} \in Y_X^T} \exp\left(S(X, \tilde{Y})\right) - S(X, Y)$$

联合学习：

$$\mathcal{L}(\theta) = \mathcal{L}_E + \mathcal{L}_R$$

对最后一个循环步构建损失：

$$\mathcal{L}_R = -\sum_{i=1}^{N} \sum_{j=1}^{N} p\left(z_{i,j}|x_i, x_j\right) \log \hat{p}\left(z_{i,j}|x_i, x_j\right)$$

信息同步单元 (Synchronization Unit)

实体同步机制（Entity Synchronization Mechanism，ESM）

- 计算每个词所属实体的语义表示：

$$\boldsymbol{u}_{t,i} = \sum_{j=1}^{N} \varphi\left(B_{i,j}^t\right) \boldsymbol{h}_j^s$$

- 更新关系检测单元的隐藏表示H_t^r：

$$\boldsymbol{h}_{t+1,i}^r = \sigma\left(\boldsymbol{u}_{t,i} W_r^4 + \boldsymbol{h}_i^s W_r^5\right)$$

关系同步机制（Relation Synchronization Mechanism，RSM）

- 计算每个词对应的关系语义表示：

$$\boldsymbol{r}_{t,i} = \sum_{j=1}^{N} \varphi\left(\phi\left(g_{i,j}^t\right)\right) \boldsymbol{h}_j^s$$

- 更新意见实体抽取单元的隐藏表示H_t^O：

$$\boldsymbol{h}_{t+1,i}^O = \sigma\left(\boldsymbol{r}_{t,i} W_O^1 + \boldsymbol{h}_i^s W_O^2\right)$$

推理层(Inference Layer)

意见实体抽取模块 预测结果： $Y=\{y_1,y_2,\dots,y_N\}$

评价方面集合： $A=\{a_1,a_2,\dots,a_{l_A}\}$

评价词集合： $O=\{o_1,o_2,\dots,o_{l_O}\}$

对于所有可能的 (评价方面，评价词) 二元组：

关系检测模块预测结果G^T + $a=\{x_{i_s^a},\dots,x_{i_e^a}\}$ $o=\{x_{i_s^o},\dots,x_{i_e^o}\}$

$$\delta=\frac{1}{2}\left(\frac{1}{|a|}\sum_{k=i_s^a}^{i_e^a}\sum_{l=i_s^o}^{i_e^o}g_{k,l}+\frac{1}{|o|}\sum_{l=i_s^o}^{i_e^o}\sum_{k=i_s^a}^{i_e^a}g_{l,k}\right)$$

当关联程度δ高于给定的阈值$\hat{\delta}$时，抽取(a,o)为意见二元组

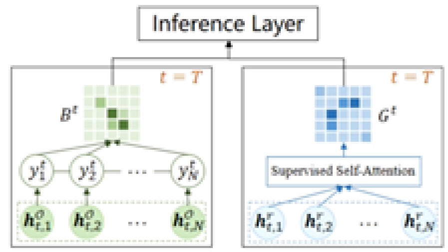

实验分析

- 数据集
  - ✓来源：
    - SemEval Challenge 2014 竞赛
    - SemEval Challenge 2015 竞赛
    - J.D. Power and Associates Sentiment Corpora
    - MPQA version 2.0
  - ✓对于三个来自 SemEval 竞赛的数据，本文基于 Wang 等人 [1,2] 对评价词的标注结果，进一步手工标注了评价方面和评价词之间的对应关系。

表1： 数据集统计

Dataset		#Sent	#A	#O	#R
SemEval-14 Restaurant	Train	3041	3693	3512	2809
	Test	800	1134	1014	936
SemEval-14 Laptop	Train	3045	2359	2500	1535
	Test	800	653	677	380
SemEval-15 Restaurant	Train	1315	1205	1217	1231
	Test	685	542	516	516
JDPA	Camera	3125	6107	4557	4144
	Car	6501	8272	11123	8709
MPQA		9471	4676	5849	4823

[1] Wang W, Pan S J, Dahlmeier D, et al. Coupled MultiLayer Attentions for Co-Extraction of Aspect and Opinion Terms. In: AAAI, 2017: 3316～3322.
[2] Wang W, Pan S J, Dahlmeier D, et al. Recursive Neural Conditional Random Fields for Aspectbased Sentiment Analysis. In: EMNLP, 2016: 616～626.

实验分析

- 评价指标：微平均F1值（Micro-F1）
- 对比算法：
  - ✓ 流水线模型（Pipeline Model）：
    - **意见实体抽取：** DE-CNN、HAST、IMN、RINANTE、SPAN
    - **关系检测：** 采用本文模型（SDRN）中的关系检测模块
  - ✓ 联合学习模型（Joint Model）：
    - **IDF**：基于强制定义因子图的方法
    - **CRF+ILP**：基于整数线性规划的 CRF 方法
    - **LSTM+SLL+RLL**：采用 LSTM 学习语义特征，并设计多个不同的联合损失函数进行模型训练。

实验分析

- 实验结果：意见二元组抽取
  - ✓ **SDRN** 在全部数据集上均取得了**最优性能**
    - SDRN、SPAN+RD 和其他对比算法相比，**BERT可以学习更丰富的上下文语义**
    - 在JDPA、MPQA数据集，SDRN **没有使用手工特征**，并取得明显提升

表2：三个SemEval数据集上意见二元组抽取结果

Models		14-Res	14-Lap	15-Res
Pipeline	HAST+RD	73.55	64.05	65.20
	DE-CNN+RD	71.02	61.11	64.19
	IMN+RD	73.69	62.98	65.56
	SPAN+RD	74.17	65.99	67.55
	RINANTE+RD	74.34	64.17	65.42
Joint	SDRN w/o ESM	74.60	66.57	69.28
	SDRN w/o RSM	75.01	66.43	69.33
	SDRN w/o ESM&RSM	74.28	65.74	67.67
	SDRN	**76.48**	**67.13**	**70.94**

表3：JDPA、MPQA数据集上意见二元组抽取结果

Models	JDPA Camera	JDPA Car	MPQA
IDF Pipeline	21.5	26.6	N/A
IDF Joint	14.1	16.1	N/A
CRF+ILP	N/A	N/A	57.04
LSTM+SLL+RLL	N/A	N/A	54.98
SDRN	**48.63**	**47.85**	**63.95**

实验分析

- 实验结果：意见二元组抽取（消融实验）
  - 单纯加深网络层数，相较于流水线的方法缺乏竞争力
  - 采用关系同步单元（RSM）或实体同步单元（ESM），模型性能会有所提升
  - 当同时采用两个同步单元时，模型取得了最优的性能

表4：三个SemEval数据集上意见二元组抽取结果

Models		14-Res	14-Lap	15-Res
Pipeline	HAST+RD	73.55	64.05	65.20
	DE-CNN+RD	71.02	61.11	64.19
	IMN+RD	73.69	62.98	65.56
	SPAN+RD	74.17	65.99	67.55
	RINANTE+RD	74.34	64.17	65.42
Joint	SDRN w/o ESM	74.60	66.57	69.28
	SDRN w/o RSM	75.01	66.43	69.33
	SDRN w/o ESM&RSM	74.28	65.74	67.67
	SDRN	**76.48**	**67.13**	**70.94**

实验分析

- 实验结果：意见实体抽取
  - 与关系检测模块进行联合训练，可以提升意见实体抽取的性能
  - aspect and opinion term co-extraction 模型优于 aspect term extraction 模型

表5：三个SemEval数据集上意见实体抽取结果

Models	14-Res		14-Lap		15-Res	
	A	O	A	O	A	O
WDEmb (Yin et al., 2016)	84.97	N/A	75.16	N/A	69.73	N/A
RNCRF† (Wang et al., 2016)	84.93	84.11	78.42	79.44	67.74	67.62
CMLA† (Wang et al., 2017)	85.29	83.18	77.80	80.17	70.73	73.68
HAST (Li et al., 2018)	85.61	85.46*	79.52	78.58*	71.46	70.77*
DE-CNN (Xu et al., 2018)	85.20	81.99*	81.59	76.34*	68.28	68.56*
IMN† (He et al., 2019)	83.33	85.61	77.96	77.51	70.04	71.94
SPAN (Hu et al., 2019)	86.20*	86.52*	80.67*	82.07*	73.65*	79.13*
GMTCMLA† (Yu et al., 2019)	84.50	85.20	78.69	79.89	70.53	72.78
RINANTE† (Dai and Song, 2019)	86.45	85.67	80.16	81.96	69.90	72.09
SDRN	**89.49**	**87.84**	**83.67**	**82.25**	**74.05**	**79.65**

实验分析

- 实验结果：收敛性分析 + 参数敏感性分析
  - 通常在 15 个 epoch 左右达到收敛，收敛速度较快
  - 随着循环步数的增加，模型的性能呈现先增加后趋于平稳（或轻微下降）的趋势，最优的结果出现在两个循环步

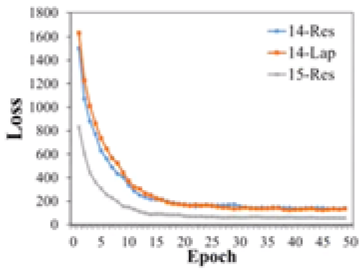

图1：收敛性分析

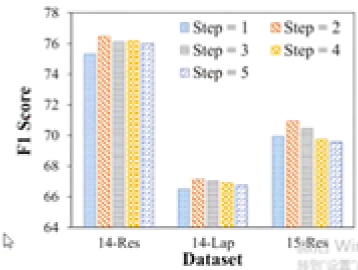

图2：参数敏感性分析

实验分析

- 实验结果：样例分析
  - **流水线模型：** 错误传导
  - **SDRN w/o ESM&RSM：** 缺乏信息交互、难以应对复杂关系

表5：样例分析

Reviews	SPAN+RD	SDRN w/o ESM&RSM	SDRN
1. The receiver was full of [superlatives]$_{1,2}$ for the [quality]$_1$ and [performance]$_2$.	(quality, superlatives) (performance, superlatives)	(receiver, superlatives) ✘ (quality, superlatives) (performance, superlatives)	(quality, superlatives) (performance, superlatives)
2. The [selection of food]$_1$ is [excellent]$_1$, and the [atmosphere]$_2$ is [great]$_2$.	(selection, excellent) ✘ (food, excellent) ✘ (atmosphere, great)	(selection of food, excellent) (atmosphere, great)	(selection of food, excellent) (atmosphere, great)
3. The [bartenders]$_1$ and the [managers]$_2$ are really [nice]$_{1,2}$ and the [decor]$_{3,4,5}$ is very [comfy]$_3$ and [laid-back]$_4$, all the while being [trendy]$_5$.	(bartenders, nice) (managers, nice) (decor, comfy) (decor, trendy)	(bartenders, nice) (managers, nice) (decor, comfy) (-, laid-back) ✘ (decor, trendy)	(bartenders, nice) (managers, nice) (decor, comfy) (decor, laid-back) (decor, trendy)

总结

- 本文关注于**意见二元组抽取（AOPE）**任务
- 本文提出了**同步双通道循环神经网络模型**
- 通过采用**词级别有监督自注意力机制**可以有效检测复杂的对应关系
- 通过**信息同步单元**使两个通道相互指导
- 论文数据和代码：https://github.com/NKU-IIPLab/SDRN

参考 中科院软件所 付成 PPT

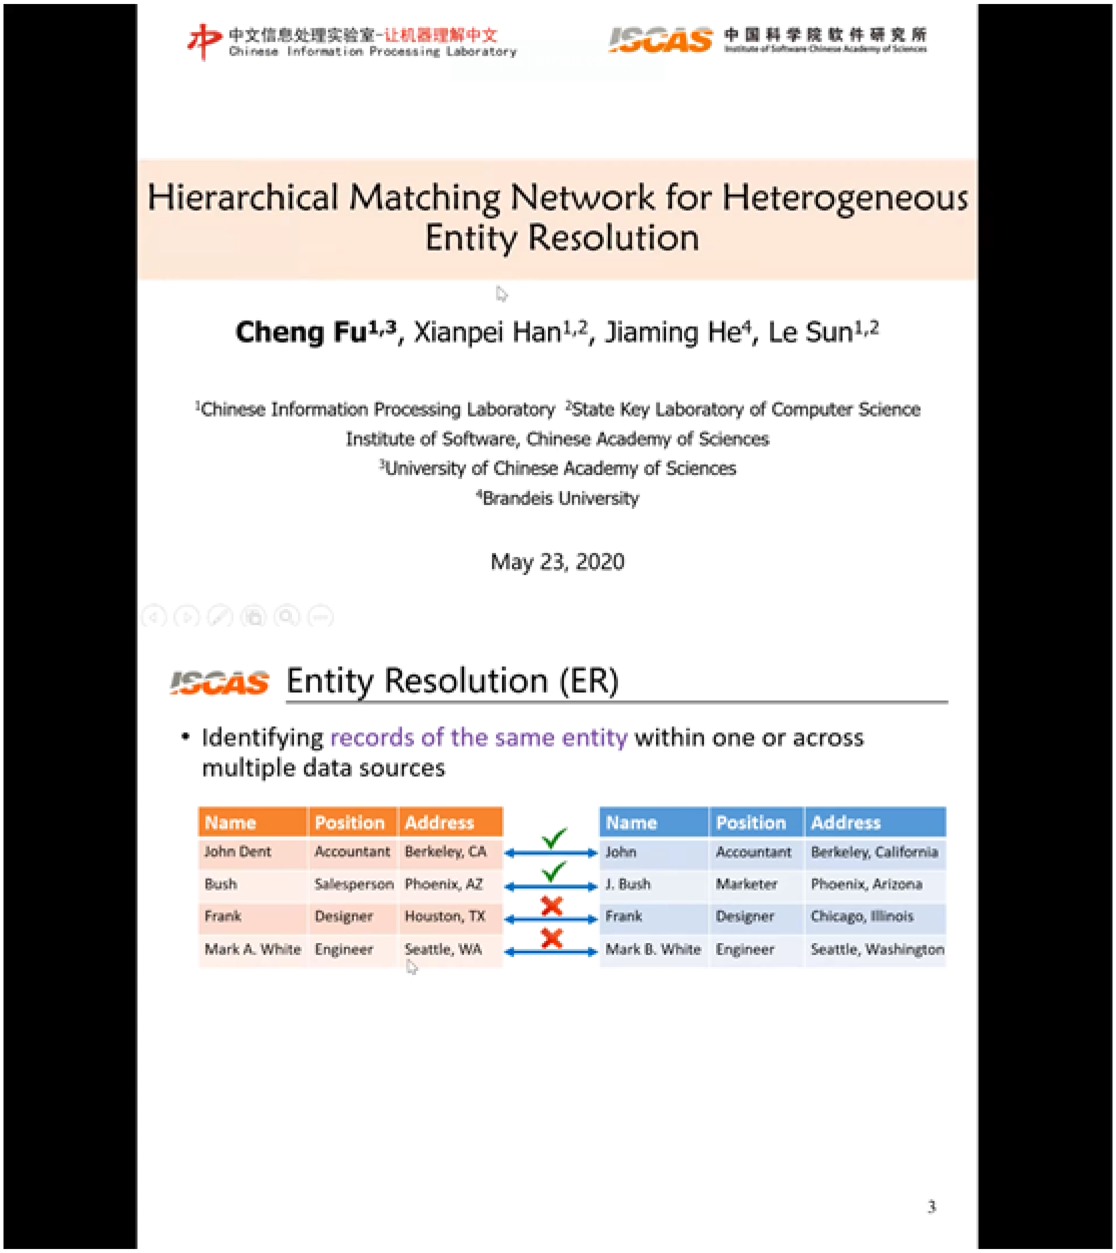

Entity Resolution (ER)

- Identifying records of the same entity within one or across multiple data sources

Name	Position	Address		Name	Position	Address
John Dent	Accountant	Berkeley, CA	✓	John	Accountant	Berkeley, California
Bush	Salesperson	Phoenix, AZ	✓	J. Bush	Marketer	Phoenix, Arizona
Frank	Designer	Houston, TX	✗	Frank	Designer	Chicago, Illinois
Mark A. White	Engineer	Seattle, WA	✗	Mark B. White	Engineer	Seattle, Washington

- Plays important roles in many tasks
  - Data mining
  - Data integration
  - Knowledge graph completion
  - Knowledge fusion
  - ...

Challenges for **Heterogeneous Entity Resolution**

- Schema heterogeneity problem

- Dirty data problem

Schema Heterogeneity Problem

- Describe the same entity using different attributes

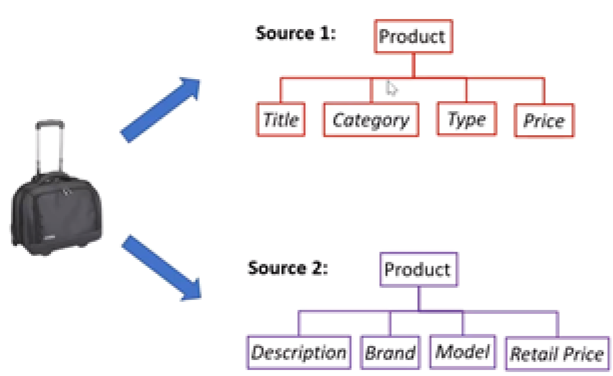

对于不同颜色的使用，使得读者更容易抓住作者想要表达的点！

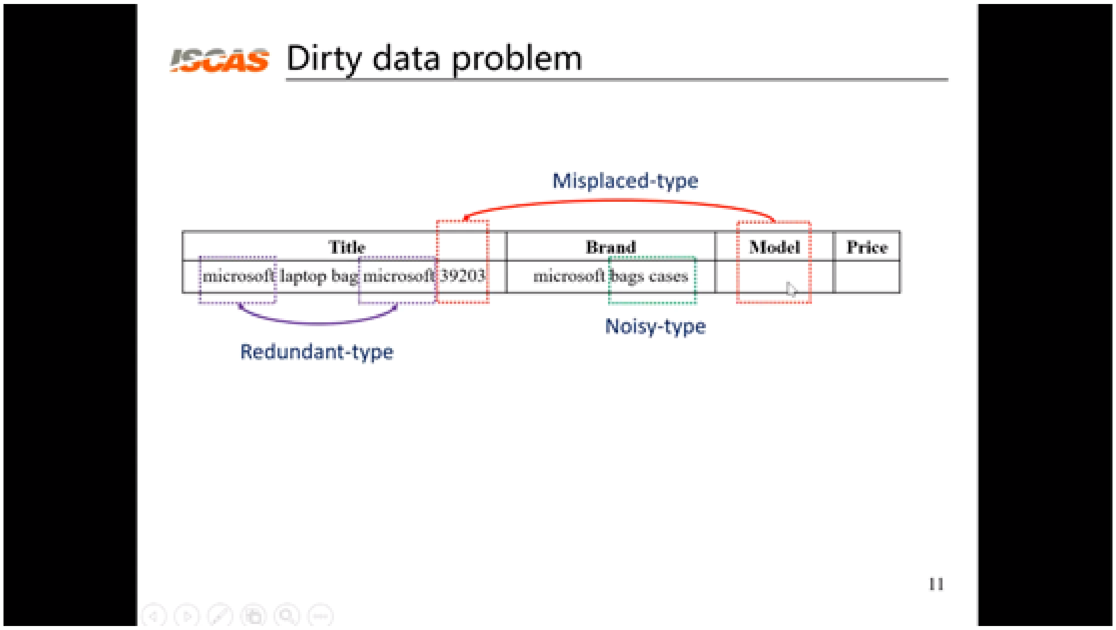

使用带背景的字体框抛出问题，抓住观众注意力。

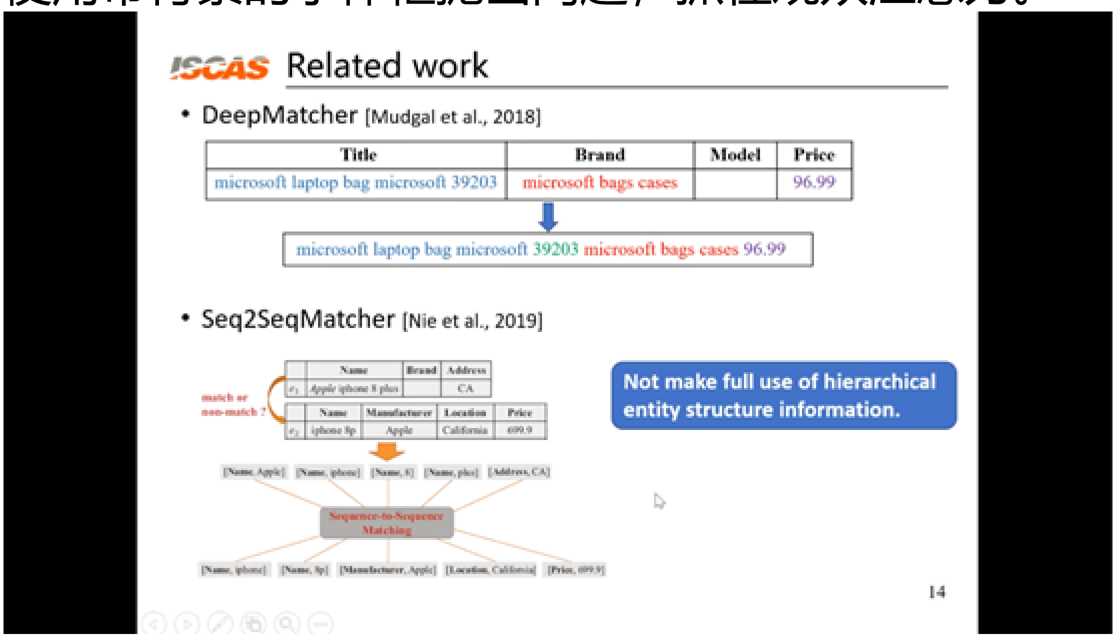

对于大纲，只突出显示马上要介绍的章节，其他的置灰。

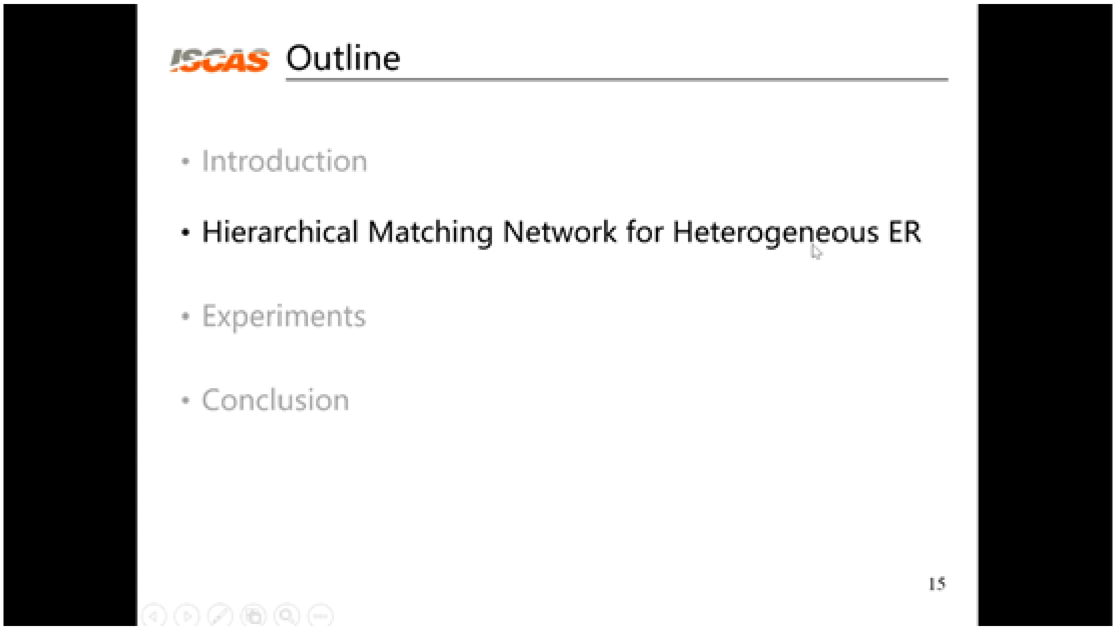

分模块介绍模型，红框标记，右边对应不同颜色文本框解释。

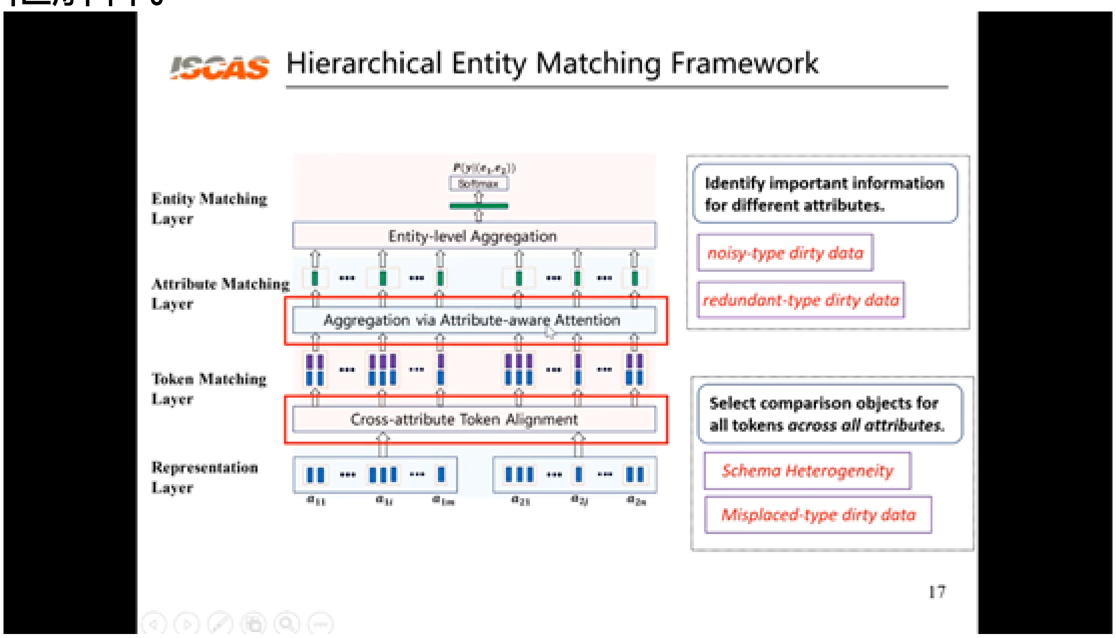

实验部分，表信息量较大时，抛出结论，使用颜色背景标记出对应数据

ISCAS Experimental Results

For heterogeneous ER

Type	Dataset	F1 score					$\Delta F1$	$\Delta F1'$
		Magellan	Deep-Matcher	MPM	Seq2Seq-Matcher	HierMatcher		
Dirty	*Walmart-Amazon*$_2$	37.4	53.8	-	68.3	**68.5**	+14.7	+0.2
	DBLP-ACM$_2$	91.9	98.1	-	**98.4**	98.1	+0.0	-0.3
	DBLP-Scholar$_2$	82.5	93.8	-	94.1	**94.5**	+0.7	+0.4
	Average	-	-	-	-	-	+5.1	+0.1
Heterogeneous	*Walmart-Amazon*$_3$(1-n)	-	67.1	-	75.6	**80.7**	+13.6	+5.1
	Walmart-Amazon$_4$(n-n)	-	63.4	-	74.7	**81.4**	+18.0	+6.7
	Walmart-Amazon$_5$(n-n)	-	66.5	-	74.4	**81.0**	+14.5	+6.6
	Average	-	-	-	-	-	+15.4	+6.1

Aligned attribute based

HierMatcher can effectively solve the schema heterogeneity and dirty data problems in ER.

ISCAS Experimental Results

Type	Dataset	F1 score		
		HierMatcher-ave	HierMatcher	
Homogeneous	*Walmart-Amazon*$_1$	77.1	**81.6**	-2.6
	Amazon-Google	70.0	**74.9**	
	DBLP-ACM$_1$	98.1	98.8	
	DBLP-Scholar$_1$	94.9	**95.3**	
	Average	-	-	
Dirty	*Walmart-Amazon*$_2$	61.4	**68.5**	-2.8
	DBLP-ACM$_2$	97.3	98.1	
	DBLP-Scholar$_2$	93.9	**94.5**	
	Average	-	-	
Heterogeneous	*Walmart-Amazon*$_3$(1-n)	67.5	**80.7**	-13.0
	Walmart-Amazon$_4$(n-n)	67.6	**81.4**	
	Walmart-Amazon$_5$(n-n)	69.0	**81.0**	
	Average	-	-	

Effectively identifying important information for each attribute is critical for ER.

ISCAS Experimental Results

Type	Dataset	F1 score						$\Delta F1$	$\Delta F1'$
		Magellan	Deep-Matcher	MPM	Seq2Seq-Matcher	HierMatcher-ave	HierMatcher		
Homogeneous	*Walmart-Amazon*$_1$	71.9	67.6	73.6	78.2	77.1	**81.6**	+8.0	+3.4
	Amazon-Google	49.1	69.3	70.7	61.2	70.0	**74.9**	+4.2	+13.7
	DBLP-ACM$_1$	98.4	98.4	-	**98.9**	98.1	98.8	+0.4	-0.1
	DBLP-Scholar$_1$	92.3	94.7	-	**95.3**	94.9	**95.3**	+0.6	+0.0
	Average	-	-	-	-	-	-	+3.3	+4.3
Dirty	*Walmart-Amazon*$_2$	37.4	53.8	-	68.3	61.4	**68.5**	+14.7	+0.2
	DBLP-ACM$_2$	91.9	98.1	-	**98.4**	97.3	98.1	+0.0	-0.3
	DBLP-Scholar$_2$	82.5	93.8	-	94.1	93.9	**94.5**	+0.7	+0.4
	Average	-	-	-	-	-	-	+5.1	+0.1
Heterogeneous	*Walmart-Amazon*$_3$(1-n)	-	67.1	-	75.6	67.5	**80.7**	+13.6	+5.1
	Walmart-Amazon$_4$(n-n)	-	63.4	-	74.7	67.6	**81.4**	+18.0	+6.7
	Walmart-Amazon$_5$(n-n)	-	66.5	-	74.4	69.0	**81.0**	+14.5	+6.6
	Average	-	-	-	-	-	-	+15.4	+6.1

HierMatcher applies to multiple types of ER scenarios.

总结，带√的项目符号很不错，且使用不同字体颜色。

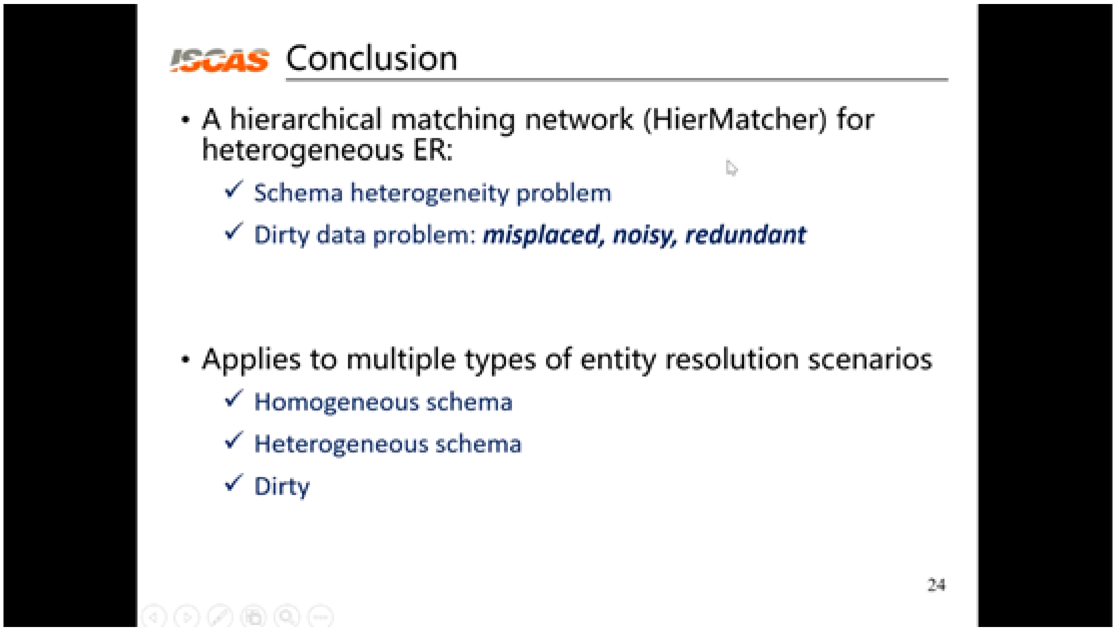

参考 北京大学 谢雨汐 PPT

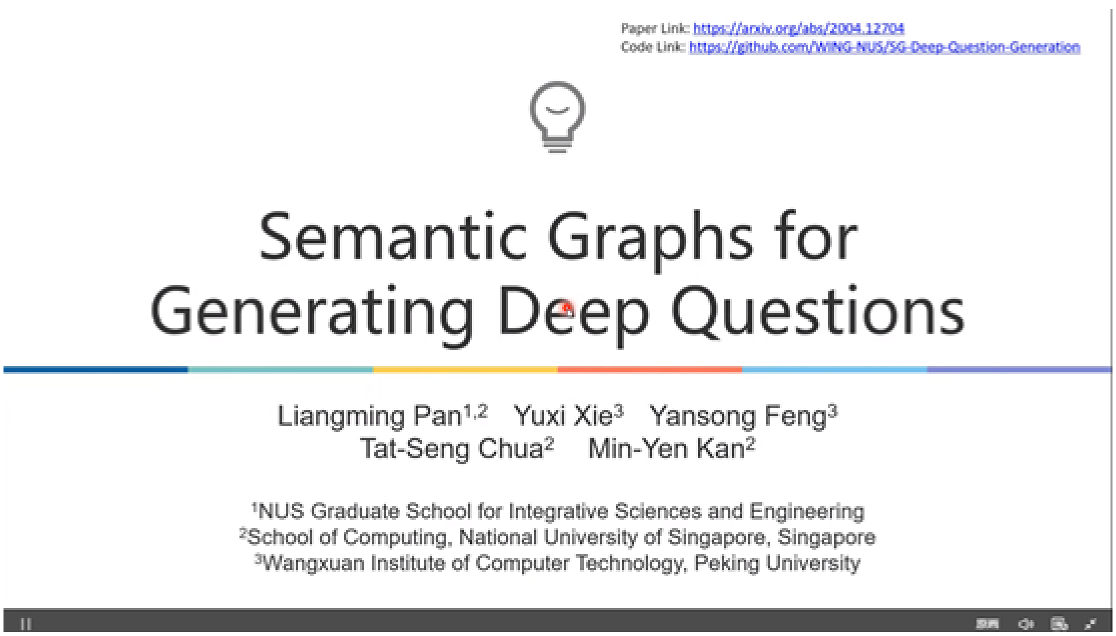

多种字体颜色的使用

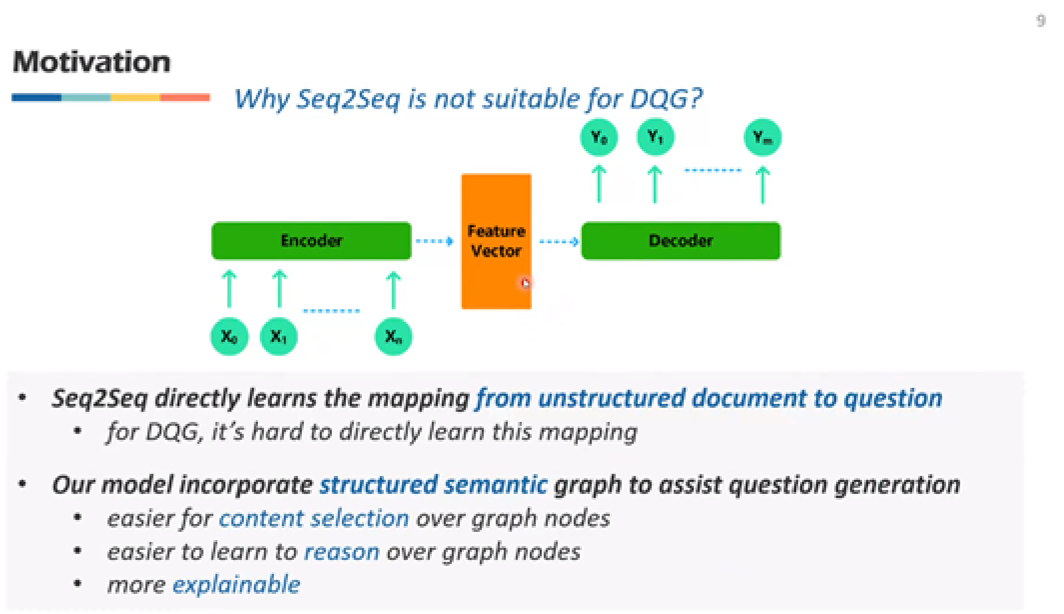

彩色模型图绘制

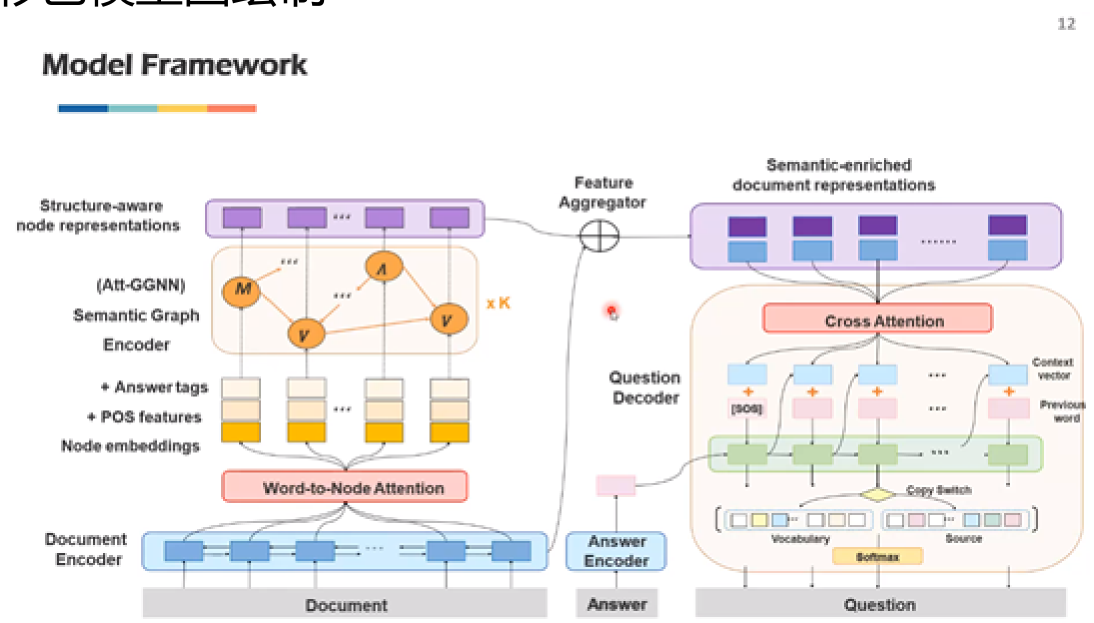

图表结论展示

Performance on Human Evaluation

- ***Fluency*** *indicates whether the question follows the grammar and accords with the correct logic*
- ***Relevance*** *indicates whether the question is answerable and relevant to the passage*
- ***Complexity*** *indicates whether the question involves reasoning over multiple sentences from the document*

Model	Short Contexts			Medium Contexts			Long Contexts			Average		
	Flu.	Rel.	Cpx.	Flu.	Rel.	Cpx.	Flu.	Rel.	Cpx.	Flu.	Rel.	Cpx.
B4. S2sa-at-mp-gsa	3.76	4.25	3.98	3.43	4.35	4.13	3.17	3.86	3.57	3.45	4.15	3.89
B6. CGC-QG	3.91	4.43	3.60	3.63	4.17	4.10	**3.69**	3.85	**4.13**	3.75	4.15	3.94
A2. -*w/o* Semantic Graph	4.01	4.43	4.15	3.65	4.41	4.12	3.54	3.88	3.55	3.73	4.24	3.94
A4. -*w/o* Multi-Task	4.11	4.58	4.28	3.81	4.27	**4.38**	3.44	3.91	3.84	3.79	4.25	4.17
P2. DP-Graph	**4.34**	**4.64**	**4.33**	**3.83**	**4.51**	4.28	3.55	**4.08**	4.04	**3.91**	**4.41**	**4.22**
G1. Ground Truth	4.75	4.87	4.74	4.65	4.73	4.73	4.46	4.61	4.55	4.62	4.74	4.67

总结，不同字体颜色突出重点。

Conclusion

- ***Propose the problem of DQG***
  - *to generate questions that requires reasoning over multiple disjoint pieces of information*
- ***Utilize semantic graphs***
  - *reduce semantic errors significantly*
  - *help do content selection – by jointly training*
    - *facilitate the reasoning process*
  - *future direction: incorporation of external knowledge*